

Raport wstępny – II Kamień Milowy

Maksim Razantsau, Oleksii Vinichenko

1 Cel systemu oraz planowane korzyści

1.1 Cel

Celem systemu jest zaprojektowanie i wdrożenie hurtowni danych integrującej informacje o przejazdach nowojorskich taksówek (TLC Trip Record Data) z historycznymi danymi pogodowymi (Open-Meteo). Zastosowano model konstelacji faktów, który umożliwia niezależną analizę zarówno zdarzeń transportowych, jak i warunków atmosferycznych.

1.2 Planowane korzyści dla odbiorcy

- Identyfikacja korelacji między pogodą a popytem na taksówki.
- Analiza średnich czasów przejazdów i opłat w różnych warunkach atmosferycznych.
- Optymalizacja liczby aktywnych pojazdów w zależności od prognozy pogody.
- Możliwość agregacji danych pogodowych niezależnie od szczegółowych przejazdów.
- Wsparcie decyzyjne w zakresie dynamicznej polityki cenowej.
- Dashboardy interaktywne w Power BI / Tableau.

2 Diagram architektury rozwiązania

Źródła danych	ETL	Hurtownia (konstelacja)	BI
TLC Parquet	PySpark / SSIS	DimDate, DimTime	Power BI / Tableau
Open-Meteo API		DimLocation, DimWeather	
		FactTrip (szcze- góły) FactWeather (agregacja go- dzinowa)	

Rysunek 1: Wysokopoziomowa architektura rozwiązania

Opis warstw:

1. **Źródła danych:** Pliki Parquet (TLC) oraz API Open-Meteo (JSON).
2. **ETL:** Ekstrakcja, czyszczenie, transformacje danych.
3. **Hurtownia:** Model konstelacji z dwoma tabelami faktów.
4. **BI:** Wizualizacja danych w postaci dashboardów oraz raportów.

3 Wykorzystywane zbiory danych

Zbiór	Dostęp	Format	Odświeżanie
TLC Trip Record Data	Publiczny (AWS/nyc.gov)	Parquet	Miesięczne (z opóźnieniem)
Open-Meteo	REST API (bezpłatny)	JSON	Codzienne

Tabela 1: Źródła danych

4 Proces ETL/ELT

4.1 Ekstrakcja


- **TLC:** Odczyt plików Parquet za pomocą PySpark (filtrowanie zakresu dat).
- **Open-Meteo:** Odczyt danych przez API.

4.2 Transformacja

- **Czyszczenie TLC:** Usunięcie wierszy z $total_amount \leq 0$, $trip_distance = 0$, $passenger_count = 0$.
- **Standaryzacja czasu:** Konwersja na timestamp i wyodrębnienie DateKey (YYY-YMMDD) oraz TimeKey (HHMMSS).
- **Dane pogodowe:** Agregacja danych 15-minutowych (Open-Meteo) do pełnych godzin.

5 Diagram modelu tabel (konstelacja faktów)

DimDate (DateKey PK, FullDate, Year, Month, Day, HolidayFlag, HolidayName)
DimTime (TimeKey PK, Hour, Minute, TimeOfDay)
DimLocation (LocationKey PK, LocationID, Borough, Zone, ServiceZone)
DimWeatherType (WeatherTypeKey PK, ConditionName, Description)



Rysunek 2: Model Konstelacji

6 Opis kluczowych miar i atrybutów

Nazwa	Tabela	Opis
TripDistance	FactTrip	Dystans przejazdu (mile)
FareAmount	FactTrip	Opłata podstawowa
TipAmount	FactTrip	Napiwek
TotalAmount	FactTrip	Całkowita opłata
TripDurationSec	FactTrip	Czas przejazdu (sekundy)
PassengerCount	FactTrip	Liczba pasażerów
Temperature	FactWeather	Temperatura (°C)
Precipitation	FactWeather	Suma opadów (mm)
WindSpeed	FactWeather	Prędkość wiatru (km/h)
ConditionName	DimWeatherType	Opis warunków (Clear, Rain, Snow)

Tabela 2: Kluczowe miary i atrybuty

7 Planowane raporty dla użytkowników

1. **Wpływ opadów na liczbę przejazdów** – wykres słupkowy / liniowy z filtrami dzielnicy i pory dnia.
2. **Średnia temperatura a czas przejazdu** – heatmapa zależności.
3. **Liczba przejazdów w kolejnych miesiącach** – analiza tendencji .
4. **Dashboard operacyjny** – karty z dzienną liczbą przejazdów, opadami, średnim napiwkiem oraz mapa natężenia ruchu.
5. **Porównanie sezonowe** – zima vs lato: średnia liczba przejazdów, opłaty, opóźnienia.
6. **Raport pogodowy godzinowy** – trendy temperatury, opadów i wiatru w czasie.